

**SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
VARAŽDIN**

Zlatko Pračić

API ZA RAD S RAZLIČITIM FORMATIMA DATOTEKA APACHE POI

**SEMINAR
NAPREDNE WEB TEHNOLOGIJE I SERVISI**

Varaždin, 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Zlatko Pračić

Matični broj: 0016145097

Studij: Baze podataka i baze znanja

Kolegij: Napredne Web tehnologije i servisi

API ZA RAD S RAZLIČITIM FORMATIMA DATOTEKA APACHE POI

SEMINAR

Mentor:

Prof. dr. sc. Dragutin Kermek

Varaždin, kolovoz 2026.

Izjava o izvornosti

Izjavljujem kako je ovaj seminar izvorni rezultat mog rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Autor potvrdio prihvatanjem odredbi u sustavu FOI Radovi

Sažetak

Opsega od 100 do 300 riječi. Sažetak upućuje na temu rada, ukratko se iznosi čime se rad bavi, teorijsko-metodološka polazišta, glavne teze i smjer rada te zaključci.

Ključne riječi: riječ; riječ; riječ; Obuhvaća 7 ± 2 ključna pojma koji su glavni predmet rasprave u radu.

Sadržaj

1. Uvod	1
2. Pregled Apache POI projekta	2
2.1. Povijest i razvoj	2
2.2. Arhitektura i komponente	2
3. Rad s formatima datoteka	4
3.1. Excel datoteke	4
3.2. Word dokumenti	4
3.3. PowerPoint prezentacije	5
4. Praktični primjeri	6
4.1. Kreiranje Word dokumenta	6
4.1.1. Zaglavlje i podnožje	6
4.1.2. Paragrafi i stilovi	7
4.1.3. Tablica	7
4.1.4. Spremanje dokumenta	8
4.2. Generiranje Excel izvještaja	8
5. Zaključak	9
Popis literature	10
Popis tablica	11
1. Prilog 1	13

1. Uvod

U suvremenom okruženju razmjena podataka putem Microsoft Office dokumenata svakodnevna je pojava. Excel tablice, Word dokumenti i PowerPoint prezentacije postali su de facto standard za izvještavanje, analizu podataka i komunikaciju. Međutim, ručna obrada takvih dokumenata u sustavima koji zahtijevaju automatizaciju, poput sustava za upravljanje sadržajem, poslovnih aplikacija ili alata za ekstrakciju podataka, nije praktična ni skalabilna.

Apache POI projekt, koji razvija i održava Apache Software Foundation, nudi rješenje za ovaj problem u obliku besplatne Java biblioteke otvorenog koda. Biblioteka programerima omogućuje čitanje, pisanje i izmjenu Microsoft Office datoteka isključivo korištenjem Java koda, bez potrebe za instaliranim Microsoft Officeom. Time se postiže potpuna platformska neovisnost, što je posebno vrijedno u enterprise okruženjima koja se oslanjaju na Java ekosustav.

Motivacija za odabir Apache POI-a kao teme ovog rada leži upravo u njegovoj rasprostranjenosti i praktičnoj primjenjivosti. Biblioteka je jedna od najkorištenijih Java biblioteka za rad s Office formatima i aktivno se razvija već više od dva desetljeća. Podržava kako starije binarne formate temeljene na OLE2 standardu (XLS, DOC, PPT), tako i moderne XML-bazirane OOXML formate uvedene s Microsoft Officeom 2007 (XLSX, DOCX, PPTX).

Cilj ovog rada je sustavno prikazati arhitekturu i ključne komponente Apache POI projekta te demonstrirati njegovu primjenu na konkretnim primjerima. Rad je strukturiran na sljedeći način: drugo poglavlje donosi pregled povijesti projekta i njegovih tehničkih komponenti, treće poglavlje opisuje rad s pojedinim formatima datoteka, a četvrto poglavlje prikazuje praktične primjere generiranja Excel izvještaja i obrade Word dokumenta. Na kraju se iznosi zaključak s osvrtom na prednosti, ograničenja i smjernice za primjenu biblioteke.

2. Pregled Apache POI projekta

2.1. Povijest i razvoj

Začeci Apache POI projekta sežu u travanj 2001. godine, kada je programer Andrew Oliver dobio kratkoročni ugovor za generiranje Excel izvještaja u Javi. Suočen s drastičnim porastom cijene komercijalne biblioteke koju je dotad koristio, Oliver je odlučio razviti vlastito rješenje otvorenog koda. Uz pomoć Marca Johnsona, kojeg je pronašao putem lokalne Java korisničke grupe, implementirana je podrška za OLE 2 *Compound Document Format* kao temelj cijelog projekta. Johnson je preuzeo razvoj niskorazinskog sloja za rukovanje OLE2 strukturom, dok je Oliver paralelno radio na parsiranju XLS formata. Već s prvim izdanjem, POI 1.0, projekt je nadišao izvorne planove, uz podršku za čitanje i pisanje Excel datoteka, dodan je i serijalizacijski okvir za integraciju s drugim sustavima [1].

Kako je projekt rastao, postalo je jasno da nadilazi okvire jednog namjenskog alata. Nakon neuspjelog pokušaja integracije isključivo u Apache Cocoon projekt, donesena je odluka da se jezgri POI API-ji prenesu u okvir Apache Jakarta projekta, dok su pojedine komponente donirane drugim projektima iz Apache ekosustava. U sklopu Jakarte, projekt je nastavio rasti zahvaljujući doprinosima zajednice, proširujući podršku na nove formate i slučajeve korištenja. Početkom 2007. godine POI je završio proces inkubacije i postao samostalni projekt najviše razine unutar *Apache Software Foundation* [1].

Naziv projekta izvorno je bio akronim za “*Poor Obfuscation Implementation*”, humoristična referenca na činjenicu kako su Microsoftovi binarni formati, unatoč naizglednoj namjernoj kompliciranosti, bili uspješno reverzno razvijeni. Ista logika imenovanja proteže se i na potprojeke poput HSSF (*Horrible SpreadSheet Format*), HWPF (*Horrible Word Processor Format*) i ostale. Kako je projekt počeo privlačiti poslovne korisnike, objašnjenja akronima tiho su uklonjena s službenih stranica [2].

2.2. Arhitektura i komponente

Apache POI organiziran je kao skup zasebnih modula, pri čemu svaki pokriva određeni format datoteke ili sloj infrastrukture. Temeljna podjela prati dvije generacije Microsoft Office formata. Stariji binarni formati, poput XLS, DOC i PPT, temelje se na OLE2 (*Object Linking and Embedding*) standardu, Microsoftovom formatu za složene dokumente koji datira iz ranih devedesetih. Za rukovanje ovim formatima POI koristi POIFS (*Poor Obfuscation Implementation File System*) komponentu koja implementira OLE2 datotečni sustav u čistoj Javi. S druge strane, uvođenjem Microsoft Officea 2007 pojavio se Office Open XML (OOXML) standard, skup formata temeljenih na XML-u i pakiranih kao ZIP arhive, koji je kasnije standardiziran kao ISO/IEC 29500. Za rad s OOXML formatima POI interno koristi openxml4j biblioteku koja implementira Open Packaging Conventions, temeljnu specifikaciju tog standarda [3].

Na ovoj infrastrukturi izgrađeni su moduli koji programerima nude intuitivan API za rad s Office dokumentima, apstrahirajući složenost internih binarnih i XML struktura. Za Excel

datoteke postoje HSSF (za stariji .xls format) i XSSF (za .xlsx), objedinjeni zajedničkim SS sučeljem koje omogućuje pisanje koda neovisnog o konkretnom formatu. Uz njih, SXSSF pruža streaming implementaciju namijenjenu pisanju izrazito velikih xlsx datoteka uz minimalan utrošak memorije. Za Word dokumente analogno postoje HWPf (za .doc) i XWPf (za .docx), a za PowerPoint prezentacije HSLF (za .ppt) i XSLF (za .pptx). Projekt uključuje i module za manje zastupljene formate, HSMF za Outlook poruke, HDGF i XDGF za Visio dijagrame te HPBF za Publisher datoteke [3].

Tablica 1: Pregled Apache POI modula

Modul	Format	Ekstenzija	Standard
POIFS	OLE2 datotečni sustav	—	OLE2
HSSF	Excel (stari)	.xls	OLE2
XSSF	Excel (novi)	.xlsx	OOXML
SXSSF	Excel (streaming)	.xlsx	OOXML
HWPf	Word (stari)	.doc	OLE2
XWPf	Word (novi)	.docx	OOXML
HSLF	PowerPoint (stari)	.ppt	OLE2
XSLF	PowerPoint (novi)	.pptx	OOXML
HSMF	Outlook poruke	.msg	OLE2
HDGF/XDGF	Visio dijagrami	.vsd/.vsdx	OLE2/OOXML
HPBF	Publisher	.pub	OLE2

3. Rad s formatima datoteka

Ovo poglavlje rada posvećeno je praktičnoj primjeni Apache POI biblioteke za rad s tri najzastupljenija Microsoft Office formata — Excel tablicama, Word dokumentima i PowerPoint prezentacijama. Za svaki format postoje dvije implementacije koje odgovaraju dvjema generacijama Office standarda: starija binarna implementacija temeljena na OLE2 formatu te novija implementacija temeljena na OOXML standardu. U nastavku su opisane ključne mogućnosti svake implementacije, uz osvrt na specifičnosti pojedinih slučajeva korištenja [3].

3.1. Excel datoteke

Za rad s Excel datotekama Apache POI nudi tri implementacije. HSSF (*Horrible Spreadsheet Format*) pokriva stariji binarni .xls format koji odgovara Excel verzijama 97–2003, a XSSF (*XML Spreadsheet Format*) namijenjen je modernom .xlsx formatu temeljenom na OOXML standardu. Oba modula podržavaju čitanje i pisanje, a dostupna je i zajednička SS apstrakcija koja omogućuje pisanje koda neovisnog o konkretnom formatu. Isti kod može generirati i .xls i .xlsx datoteku promjenom jednog parametra. Kroz ove module moguće je kreirati radne knjige i listove, postavljati vrijednosti ćelija, primjenjivati stilove i formate, koristiti formule te upravljati uvjetnim oblikovanjem [4].

Za slučajeve kada je potrebno generirati izrazito velike Excel datoteke, standardni XSSF pristup može biti problematičan zbog visokog memorijskog opterećenja, cijela struktura dokumenta drži se u memoriji. Kao rješenje, od verzije 3.8-beta3 dostupan je SXSSF (*Streaming Spreadsheet Format*), streaming implementacija izgrađena povrh XSSF-a. SXSSF postiže mali memorijski otisak ograničavanjem pristupa samo redovima unutar kliznog prozora fiksne veličine, dok se stariji redovi automatski zapisuju na disk. Veličina prozora može se konfigurirati pri inicijalizaciji radne knjige ili zasebno po listu. Važno je napomenuti kako je SXSSF namijenjen isključivo pisanju, za čitanje velikih datoteka preporučuje se korištenje SAX-temeljenog Event modela koji XML strukturu .xlsx datoteke procesira inkrementalno [4].

3.2. Word dokumenti

Za rad s Word dokumentima Apache POI nudi dvije implementacije. HWPf (*Horrible Word Processor Format*) pokriva stariji binarni .doc format koji odgovara Word verzijama 97–2003, a XWPf (*XML Word Processor Format*) namijenjen je modernom .docx formatu temeljenom na OOXML standardu. HWPf podržava čitanje i ograničeno pisanje, a pruža i jednostavnu ekstrakciju teksta za još starije Word 6 i Word 95 formate. XWPf nudi stabilniji i potpuniji API te podržava čitanje i pisanje složenijih dokumenata [5].

Glavna ulazna točka za rad s .docx datotekama je klasa XWPfDocument, iz koje se dohvaćaju svi elementi dokumenta. Paragrafi su dostupni kroz klasu XWPfParagraph, a svaki paragraf sastoji se od jednog ili više XWPfRun objekata koji predstavljaju tekstualne odsječke s jednakim stilskim svojstvima: fontom, veličinom, podebljavanjem, nakošenje slova

i slično. Tablice se dohvaćaju kroz klasu `XWPFTable`, pri čemu su pojedini redovi i ćelije dostupni kroz `XWPFTableRow` i `XWPFTableCell`. Za ekstrakciju cjelokupnog teksta dokumenta u jednom koraku dostupna je klasa `XWPFWordExtractor`. Zaglavlja i podnožja dostupna su kroz `XWPFHeader` i `XWPFHeaderFooterPolicy` klase putem `XWPFHeaderFooterPolicy` objekta [5].

3.3. PowerPoint prezentacije

Za rad s PowerPoint prezentacijama Apache POI nudi dvije implementacije. `HSLF` (*Horrible Slide Layout Format*) pokriva stariji binarni `.ppt` format koji odgovara PowerPoint verzijama 97–2003, a `XSLF` (*XML Slide Layout Format*) namijenjen je modernom `.pptx` formatu temeljenom na OOXML standardu. Za razliku od Excel modula koji dijele zajednički SS API, `HSLF` i `XSLF` trenutno nemaju zajedničko sučelje, što znači da kod napisan za jedan format nije izravno prenosiv na drugi [6].

Glavna ulazna točka za rad s `.pptx` datotekama je klasa `XMLSlideShow`, dok je za stariji `.ppt` format to `HSLFSlideShow`. Prezentacija se sastoji od hijerarhijske strukture: prezentacija sadržava slajdove, svaki slajd sadržava oblike (`shapes`), a svaki oblik može sadržavati tekstualne okvire i odlomke. Slajdovi se kreiraju metodom `createSlide()`, pri čemu je moguće odabrati željeni predložak rasporeda (*slide layout*) iz dostupnih rasporeda slide mastera. Oblici poput tekstualnih okvira, slika i tablica dodaju se metodama poput `createTextBox()` i `addPicture()`. Za naprednije slučajeve korištenja, `XSLFSlide` objekt implementira metodu `draw()` koja omogućuje iscrtavanje cijelog slajda na Java `Graphics2D` objekt, što je korisno za generiranje slika ili PDF-ova iz prezentacija [6].

4. Praktični primjeri

Za demonstraciju praktične primjene Apache POI biblioteke koristi se Eclipse IDE uz Maven kao alat za upravljanje ovisnostima. Maven omogućuje jednostavno upravljanje vanjskim bibliotekama kroz centralnu konfiguracijsku datoteku `pom.xml`, čime se izbjegava ručno preuzimanje i dodavanje JAR datoteka u classpath projekta [7].

Nakon kreiranja novog Maven projekta u Eclipseu putem `File → New → Maven Project`, u datoteku `pom.xml` potrebno je dodati dvije ovisnosti. Ovisnost `poi` pokriva podršku za starije binarne formate te predstavlja jezgrenu biblioteku projekta, dok ovisnost `poi-ooxml` dodaje podršku za moderne OOXML formate. Maven automatski preuzima sve tranzitivne ovisnosti, pa nije potrebno ručno upravljati dodatnim JAR datotekama. Trenutno aktualna stabilna verzija Apache POI biblioteke je 5.5.1. [7]

```
1 <dependency>
2   <groupId>org.apache.poi</groupId>
3   <artifactId>poi</artifactId>
4   <version>5.5.1</version>
5 </dependency>
6 <dependency>
7   <groupId>org.apache.poi</groupId>
8   <artifactId>poi-ooxml</artifactId>
9   <version>5.5.1</version>
10</dependency>
```

Isječak koda 1: Ovisnosti u datoteci `pom.xml`

4.1. Kreiranje Word dokumenta

Kreiranje Word dokumenta u Apache POI-u temelji se na klasi `XWPFDocument`, koja predstavlja glavni objekt dokumenta. Iz nje se kreiraju svi ostali elementi — zaglavlja, podnožja, paragrafi i tablice.

4.1.1. Zaglavlje i podnožje

Zaglavlje i podnožje kreiraju se metodama `createHeader()` i `createFooter()` uz parametar `HeaderFooterType.DEFAULT`, koji označava da se primjenjuju na sve stranice dokumenta. Unutar zaglavlja i podnožja kreira se paragraf, a tekst se dodaje kroz `XWPFRun` objekt. Isti princip — paragraf koji sadrži jedan ili više `XWPFRun` objekata — koristi se za sve tekstualne elemente u dokumentu.

```
1 XWPFHeader zaglavlje = dokument.createHeader(HeaderFooterType.DEFAULT);
2 XWPFParagraph zaglavljeParagraf = zaglavlje.createParagraph();
3 zaglavljeParagraf.setAlignment(ParagraphAlignment.CENTER);
4 XWPFRun zaglavljeRun = zaglavljeParagraf.createRun();
5 zaglavljeRun.setText("Fakultet organizacije i informatike");
```

```

6 zaglavljeRun.setFontSize(10);
7 zaglavljeRun.setColor("888888");

```

Isječak koda 2: Obrada Word dokumenta

4.1.2. Paragrafi i stilovi

Paragrafi se kreiraju metodom `createParagraph()` na objektu dokumenta. Svaki paragraf može imati postavljeno poravnanje (`setAlignment()`), razmak prije ili nakon (`setSpacingBefore()`, `setSpacingAfter()`) te jedan ili više `XWPFRun` objekata koji nose stvarni tekst. Na razini `XWPFRun` objekta definiraju se stilska svojstva teksta: font (`setFontFamily()`), veličina (`setFontSize()`), boja (`setColor()`), podebljanje (`setBold()`) i kurziv (`setItalic()`). U primjeru su na ovaj način kreirani naslov, podnaslov, uvodni paragraf i završna napomena.

```

1 XWPFParagraph naslov = dokument.createParagraph();
2 naslov.setAlignment(ParagraphAlignment.CENTER);
3 naslov.setSpacingAfter(200);
4 XWPFRun naslovRun = naslov.createRun();
5 naslovRun.setText("Popis studenata i ocjena");
6 naslovRun.setBold(true);
7 naslovRun.setFontSize(20);
8 naslovRun.setFontFamily("Calibri");

```

Isječak koda 3: Kreiranje naslova

4.1.3. Tablica

Tablica se kreira metodom `createTable()` uz navođenje broja redova i stupaca. U primjeru je kreirana tablica s 6 redova i 3 stupca — prvi red služi kao zaglavlje tablice, a preostalih 5 redova sadrži podatke o studentima.

Zaglavlje tablice stilizira se plavom pozadinskom bojom (`setColor()`) i bijelim podebljanim tekstom. Svaka ćelija zaglavlja dohvaća se metodom `getCell()` iz odgovarajućeg reda, a tekst se dodaje na isti način kao i u paragrafima dokumenta — kroz `XWPFParagraph` i `XWPFRun` objekte.

```

1 XWPFTable tablica = dokument.createTable(6, 3);
2 tablica.setWidth("100%");
3
4 String[] zaglavljaStupaca = {"Ime i prezime", "JMBAG", "Ocjena"};
5 XWPFTableRow zaglavljeRed = tablica.getRow(0);
6 for (int i = 0; i < zaglavljaStupaca.length; i++) {
7     XWPFTableCell celija = zaglavljeRed.getCell(i);
8     celija.setColor("2E75B6");
9     XWPFParagraph p = celija.getParagraphs().get(0);
10    p.setAlignment(ParagraphAlignment.CENTER);

```

```

11     XWPFRun r = p.createRun();
12     r.setText(zaglavljajaStupaca[i]);
13     r.setBold(true);
14     r.setColor("FFFFFF");
15     r.setFontSize(11);
16 }

```

Isječak koda 4: Kreiranje zaglavlja tablice

Redovi s podacima pune se iteracijom kroz dvodimenzionalno polje. Radi bolje čitljivosti, primijenjeno je izmjenično bojanje redova — parni redovi ostaju bijeli, a neparni dobivaju svijetloplavu pozadinsku boju.

```

1  for (int i = 0; i < podaci.length; i++) {
2      XWPFTableRow red = tablica.getRow(i + 1);
3      String boja = (i % 2 == 0) ? "FFFFFF" : "DEEAF1";
4      for (int j = 0; j < podaci[i].length; j++) {
5          XWPFTableCell celija = red.getCell(j);
6          celija.setColor(boja);
7          XWPFParagraph p = celija.getParagraphs().get(0);
8          p.setAlignment(ParagraphAlignment.CENTER);
9          XWPFRun r = p.createRun();
10         r.setText(podaci[i][j]);
11         r.setFontSize(11);
12     }
13 }

```

Isječak koda 5: Punjenje tablice podacima

4.1.4. Spremanje dokumenta

Po završetku izgradnje dokumenta, korištenjem `FileOutputStream` sadržaj se zapisuje u datoteku objekta. Preporučuje se korištenje `try-with-resources` bloka koji osigurava automatsko zatvaranje toka podataka nakon zapisivanja, čime se sprječava curenje resursa.

```

1  try (FileOutputStream out = new FileOutputStream("studenti.docx")) {
2      dokument.write(out);
3  }
4  dokument.close();

```

Isječak koda 6: Spremanje dokumenta

4.2. Generiranje Excel izvještaja

Primjer automatskog generiranja tablice i grafa iz podataka.

```

1  % TODO: dodaj Java kod ovdje

```

Isječak koda 7: Generiranje Excel izvještaja

5. Zaključak

Sažetak ključnih spoznaja i smjernice za primjenu Apache POI-a.

Popis literature

- [1] *Apache POI; Project History* — *poi.apache.org*, <https://poi.apache.org/development/history/index.html>, [Pristupljeno 24. travnja 2026.]
- [2] *Apache POI - Wikipedia* — *en.wikipedia.org*, https://en.wikipedia.org/wiki/Apache_POI_history_and_roadmap, [Pristupljeno 24. travnja 2026.]
- [3] *Apache POI-Component Overview* — *poi.apache.org*, <https://poi.apache.org/components/>, [Pristupljeno 25. travnja 2026.]
- [4] *POI-HSSF and POI-XSSF/SXSSF - Java API To Access Microsoft Excel Format Files* — *poi.apache.org*, <https://poi.apache.org/components/spreadsheet/>, [Pristupljeno 29. travnja 2026.]
- [5] *Apache POI-HWPF and XWPF - Java API to Handle Microsoft Word Files*, <https://poi.apache.org/components/document/>, [Pristupljeno 29. travnja 2026.]
- [6] *Apache POI-HSLF - A Quick Guide* — *poi.apache.org*, <https://poi.apache.org/components/slideshow/quick-guide.html>, [Pristupljeno 29. travnja 2026.]
- [7] *Apache POI - Download Release Artifacts* — *poi.apache.org*, <https://poi.apache.org/download.html>, [Pristupljeno 05. svibnja 2026.]

Popis tablica

1. Pregled Apache POI modula	3
--	---

Prilozi

1. Prilog 1