

**SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
VARAŽDIN**

Zlatko Pračić

API ZA RAD S RAZLIČITIM FORMATIMA DATOTEKA APACHE POI

**SEMINAR
NAPREDNE WEB TEHNOLOGIJE I SERVISI**

Varaždin, 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Zlatko Pračić

Matični broj: 0016145097

Studij: Baze podataka i baze znanja

Kolegij: Napredne Web tehnologije i servisi

API ZA RAD S RAZLIČITIM FORMATIMA DATOTEKA APACHE POI

SEMINAR

Mentor:

Prof. dr. sc. Dragutin Kermek

Varaždin, kolovoz 2026.

Izjava o izvornosti

Izjavljujem kako je ovaj seminar izvorni rezultat mog rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Autor potvrdio prihvatanjem odredbi u sustavu FOI Radovi

Sažetak

Opsega od 100 do 300 riječi. Sažetak upućuje na temu rada, ukratko se iznosi čime se rad bavi, teorijsko-metodološka polazišta, glavne teze i smjer rada te zaključci.

Ključne riječi: riječ; riječ; riječ; Obuhvaća 7 ± 2 ključna pojma koji su glavni predmet rasprave u radu.

Sadržaj

1. Uvod	1
2. Pregled Apache POI projekta	2
2.1. Povijest i razvoj	2
2.2. Arhitektura i komponente	2
3. Rad s formatima datoteka	4
3.1. Excel datoteke	4
3.2. Word dokumenti	4
3.3. PowerPoint prezentacije	4
4. Praktični primjeri	5
4.1. Generiranje Excel izvještaja	5
4.2. Obrada Word dokumenta	5
5. Zaključak	6
Popis literature	7
Popis tablica	8
1. Prilog 1	10

1. Uvod

U suvremenom okruženju razmjena podataka putem Microsoft Office dokumenata svakodnevna je pojava. Excel tablice, Word dokumenti i PowerPoint prezentacije postali su de facto standard za izvještavanje, analizu podataka i komunikaciju. Međutim, ručna obrada takvih dokumenata u sustavima koji zahtijevaju automatizaciju, poput sustava za upravljanje sadržajem, poslovnih aplikacija ili alata za ekstrakciju podataka, nije praktična ni skalabilna.

Apache POI projekt, koji razvija i održava Apache Software Foundation, nudi rješenje za ovaj problem u obliku besplatne Java biblioteke otvorenog koda. Biblioteka programerima omogućuje čitanje, pisanje i izmjenu Microsoft Office datoteka isključivo korištenjem Java koda, bez potrebe za instaliranim Microsoft Officeom. Time se postiže potpuna platformaska neovisnost, što je posebno vrijedno u enterprise okruženjima koja se oslanjaju na Java ekosustav.

Motivacija za odabir Apache POI-a kao teme ovog rada leži upravo u njegovoj rasprostranjenosti i praktičnoj primjenjivosti. Biblioteka je jedna od najkorištenijih Java biblioteka za rad s Office formatima i aktivno se razvija već više od dva desetljeća. Podržava kako starije binarne formate temeljene na OLE2 standardu (XLS, DOC, PPT), tako i moderne XML-bazirane OOXML formate uvedene s Microsoft Officeom 2007 (XLSX, DOCX, PPTX).

Cilj ovog rada je sustavno prikazati arhitekturu i ključne komponente Apache POI projekta te demonstrirati njegovu primjenu na konkretnim primjerima. Rad je strukturiran na sljedeći način: drugo poglavlje donosi pregled povijesti projekta i njegovih tehničkih komponenti, treće poglavlje opisuje rad s pojedinim formatima datoteka, a četvrto poglavlje prikazuje praktične primjere generiranja Excel izvještaja i obrade Word dokumenta. Na kraju se iznosi zaključak s osvrtom na prednosti, ograničenja i smjernice za primjenu biblioteke.

2. Pregled Apache POI projekta

2.1. Povijest i razvoj

Začeci Apache POI projekta sežu u travanj 2001. godine, kada je programer Andrew Oliver dobio kratkoročni ugovor za generiranje Excel izvještaja u Javi. Suočen s drastičnim porastom cijene komercijalne biblioteke koju je dotad koristio, Oliver je odlučio razviti vlastito rješenje otvorenog koda. Uz pomoć Marca Johnsona, kojeg je pronašao putem lokalne Java korisničke grupe, implementirana je podrška za OLE 2 *Compound Document Format* kao temelj cijelog projekta. Johnson je preuzeo razvoj niskorazinskog sloja za rukovanje OLE2 strukturom, dok je Oliver paralelno radio na parsiranju XLS formata. Već s prvim izdanjem, POI 1.0, projekt je nadišao izvorne planove, uz podršku za čitanje i pisanje Excel datoteka, dodan je i serijalizacijski okvir za integraciju s drugim sustavima [1].

Kako je projekt rastao, postalo je jasno da nadilazi okvire jednog namjenskog alata. Nakon neuspjelog pokušaja integracije isključivo u Apache Cocoon projekt, donesena je odluka da se jezgri POI API-ji prenesu u okvir Apache Jakarta projekta, dok su pojedine komponente donirane drugim projektima iz Apache ekosustava. U sklopu Jakarte, projekt je nastavio rasti zahvaljujući doprinosima zajednice, proširujući podršku na nove formate i slučajeve korištenja. Početkom 2007. godine POI je završio proces inkubacije i postao samostalni projekt najviše razine unutar *Apache Software Foundation* [1].

Naziv projekta izvorno je bio akronim za "*Poor Obfuscation Implementation*", humoristična referenca na činjenicu kako su Microsoftovi binarni formati, unatoč naizglednoj namjernoj kompliciranosti, bili uspješno reverzno razvijeni. Ista logika imenovanja proteže se i na potprojeke poput HSSF (*Horrible SpreadSheet Format*), HWPf (*Horrible Word Processor Format*) i ostale. Kako je projekt počeo privlačiti poslovne korisnike, objašnjenja akronima tiho su uklonjena s službenih stranica [2].

2.2. Arhitektura i komponente

Apache POI organiziran je kao skup zasebnih modula, pri čemu svaki pokriva određeni format datoteke ili sloj infrastrukture. Temeljna podjela prati dvije generacije Microsoft Office formata. Stariji binarni formati, poput XLS, DOC i PPT, temelje se na OLE2 (*Object Linking and Embedding*) standardu, Microsoftovom formatu za složene dokumente koji datira iz ranih devedesetih. Za rukovanje ovim formatima POI koristi POIFS (*Poor Obfuscation Implementation File System*) komponentu koja implementira OLE2 datotečni sustav u čistoj Javi. S druge strane, uvođenjem Microsoft Officea 2007 pojavio se Office Open XML (OOXML) standard, skup formata temeljenih na XML-u i pakiranih kao ZIP arhive, koji je kasnije standardiziran kao ISO/IEC 29500. Za rad s OOXML formatima POI interno koristi openxml4j biblioteku koja implementira Open Packaging Conventions, temeljnu specifikaciju tog standarda [3].

Na ovoj infrastrukturi izgrađeni su moduli koji programerima nude intuitivan API za rad s Office dokumentima, apstrahirajući složenost internih binarnih i XML struktura. Za Excel

datoteke postoje HSSF (za stariji .xls format) i XSSF (za .xlsx), objedinjeni zajedničkim SS sučeljem koje omogućuje pisanje koda neovisnog o konkretnom formatu. Uz njih, SXSSF pruža streaming implementaciju namijenjenu pisanju izrazito velikih xlsx datoteka uz minimalan utrošak memorije. Za Word dokumente analogno postoje HWPf (za .doc) i XWPf (za .docx), a za PowerPoint prezentacije HSLF (za .ppt) i XSLF (za .pptx). Projekt uključuje i module za manje zastupljene formate, HSMF za Outlook poruke, HDGF i XDGF za Visio dijagrame te HPBF za Publisher datoteke [3].

Tablica 1: Pregled Apache POI modula

Modul	Format	Ekstenzija	Standard
POIFS	OLE2 datotečni sustav	—	OLE2
HSSF	Excel (stari)	.xls	OLE2
XSSF	Excel (novi)	.xlsx	OOXML
SXSSF	Excel (streaming)	.xlsx	OOXML
HWPf	Word (stari)	.doc	OLE2
XWPf	Word (novi)	.docx	OOXML
HSLF	PowerPoint (stari)	.ppt	OLE2
XSLF	PowerPoint (novi)	.pptx	OOXML
HSMF	Outlook poruke	.msg	OLE2
HDGF/XDGF	Visio dijagrami	.vsd/.vsdx	OLE2/OOXML
HPBF	Publisher	.pub	OLE2

3. Rad s formatima datoteka

3.1. Excel datoteke

Čitanje i pisanje .xls (HSSF) i .xlsx (XSSF) formata, formatiranje ćelija, formule te SXSSF Streaming API za velike datoteke.

3.2. Word dokumenti

Rukovanje .doc (HWPF) i .docx (XWPF) formatima, paragrafi, tablice i stilovi.

3.3. PowerPoint prezentacije

Rukovanje .ppt (HSLF) i .pptx (XSLF) formatima, slajdovi i oblici.

4. Praktični primjeri

4.1. Generiranje Excel izvještaja

Primjer automatskog generiranja tablice i grafa iz podataka.

4.2. Obrada Word dokumenta

Primjer čitanja i izmjene postojećeg .docx dokumenta.

5. Zaključak

Sažetak ključnih spoznaja i smjernice za primjenu Apache POI-a.

Popis literature

- [1] *Apache POI; Project History* — *poi.apache.org*, <https://poi.apache.org/development/history/index.html>, [Pristupljeno 24. travnja 2026.]
- [2] *Apache POI - Wikipedia* — *en.wikipedia.org*, https://en.wikipedia.org/wiki/Apache_POI_history_and_roadmap, [Pristupljeno 24. travnja 2026.]
- [3] *Apache POI - Component Overview* — *poi.apache.org*, <https://poi.apache.org/components/>, [Pristupljeno 25. travnja 2026.]

Popis tablica

1. Pregled Apache POI modula	3
--	---

Prilozi

1. Prilog 1